

# **MAT 3775**

## **Analyse de la régression**

### **Chapitre 1**

### **Préliminaires**

P. Boily (uOttawa)

Session d'hiver – 2023

P. Boily (uOttawa)

## Aperçu

### 1.1 – Variables aléatoires (p.3)

- Espérance, variance, et covariance (p.4)
- Distributions importantes (p.13)

### 1.2 – Calcul multivarié (p.22)

### 1.3 – Algèbre matricielle (p.23)

### 1.4 – Formes quadratiques (p.25)

- Théorème de Cochran (p.29)
- Formes quadratiques importantes (p.30)

### 1.5 – Optimisation (p.32)

## 1 – Préliminaires

L'analyse de régression n'est pas une discipline très compliquée ... à condition de bien maîtriser ses pré-requis. Dans ce cours, il sera utile de se familiariser avec un certain nombre de notions relatives :

- aux **variables aléatoires** ;
- au **calcul à plusieurs variables** ;
- à l'**algèbre linéaire** ;
- aux **formes quadratiques**, et
- à l'**optimisation**.

## 1.1 – Variables aléatoires

Une **épreuve aléatoire** est un **processus** pour lequel il est impossible de prédire le **résultat avec certitude**. L'**espace d'échantillonnage**  $\mathcal{S}$  est l'ensemble des **résultats possibles** de l'épreuve aléatoire.

Une **variable aléatoire**  $Y$  associée est une **fonction**  $Y : \mathcal{S} \rightarrow \mathbb{R}$ . Si l'ensemble  $Y(\mathcal{S}) = \{Y(s) \mid s \in \mathcal{S}\}$  est **dénombrable**,  $Y$  est une **variable aléatoire discrète** ; s'il ne l'est pas,  $Y$  est une **variable aléatoire continue**.

À chaque v.a.  $Y$  correspond une **fonction de probabilité**  $f(Y)$ , qui spécifie les **probabilités des valeurs prises par  $Y$** .

$Y_1$  et  $Y_2$  sont **indépendantes** lorsque leur **f.d.p. conjointe**  $f(Y_1, Y_2)$  est le produit des **f.d.p. individuelles**  $f(Y_1)f(Y_2)$ .

### 1.1.1 – Espérance, variance, et covariance

L'opérateur d'espérance  $E\{\cdot\}$  est défini par

$$E\{Y\} = \begin{cases} \sum_{Y(s)} Y(s)f(Y(s)), & \text{si } Y \text{ est discrète} \\ \int_{\mathbb{R}} Y f(Y) dy, & \text{si } Y \text{ est continue} \end{cases}$$

L'espérance  $E\{Y\}$  est la **valeur moyenne** que l'on s'attend à observer si l'expérience est répétée à maintes reprises.

L'espérance est parfois aussi appelée la **moyenne** de  $Y$ , notée  $\bar{Y}$  ; c'est donc une mesure de la **tendance centrale** de  $Y$ .

L'opérateur de **variance**  $\sigma^2 \{ \cdot \}$  est défini par

$$\sigma^2 \{Y\} = E \left\{ (Y - E \{Y\})^2 \right\} = E \{Y^2\} - (E \{Y\})^2.$$

Il est souvent désigné par  $\text{Var}(Y)$ . C'est une mesure de la **dispersion** de  $Y$  (les grandes variances sont associées à de **fortes dispersions**, et *vice-versa*).

L'opérateur de **covariance**  $\sigma \{ \cdot, \cdot \}$  est défini par

$$\sigma \{Y, W\} = E \{ (Y - E \{Y\}) (W - E \{W\}) \} = E \{YW\} - E \{Y\} E \{W\}.$$

Il est souvent désigné par  $\text{Cov}(Y, W)$ . C'est une mesure de la **force de la relation linéaire** entre deux v.a. (les grandes magnitudes de covariance sont associées à la **linéarité**, mais “grand” est un concept relatif).

L'opérateur **écart-type**  $\sigma \{ \cdot \}$  est défini par

$$\sigma \{Y\} = \sqrt{\sigma^2 \{Y\}}.$$

Il est toujours non négatif.

L'opérateur **de corrélation**  $\rho \{ \cdot, \cdot \}$  est défini par

$$\rho \{Y, W\} = \frac{\sigma \{Y, W\}}{\sigma \{Y\} \sigma \{W\}},$$

en supposant que  $\sigma \{Y\} \sigma \{W\} \neq 0$ .

Lorsque  $\rho \{Y, W\} = 0$ , on dit que les v.a. sont **non corrélées**.

## Propriétés des opérateurs

Soient  $Y, Y_i, W$  des v.a., et  $a, b, c, a_i, b_i, c_i \in \mathbb{R}$ ,  $i = 1, \dots, n$ . Alors :

- $E\{\cdot\}$  est **linéaire** sur l'espace de v.a. :  $E\{aY + b\} = aE\{Y\} + b$  et

$$E\left\{\sum_{i=1}^n a_i Y_i\right\} = \sum_{i=1}^n a_i E\{Y_i\}$$

- $\sigma^2\{aY + b\} = a^2\sigma^2\{Y\}$  et

$$\sigma^2\left\{\sum_{i=1}^n a_i Y_i\right\} = \sum_{i=1}^n \sum_{j=1}^n a_i a_j \sigma\{Y_i, Y_j\} = \sum_{i=1}^n a_i^2 \sigma^2\{Y_i\} + \sum_{i \neq j} a_i a_j \sigma\{Y_i, Y_j\}$$



- $\sigma\{Y, Y\} = \sigma^2\{Y\}$  et  $\sigma\{Y, W\} = \sigma\{W, Y\}$
- $\sigma\{a_1Y + b_1, a_2W + b_2\} = a_1a_2\sigma\{Y, W\}$
- $\{Y_i\}$  **sans corrélation**  $\implies$

$$\sigma\left\{\sum_{i=1}^n a_i Y_i, \sum_{i=1}^n c_i Y_i\right\} = \sum_{i=1}^n a_i c_i \sigma^2\{Y_i\}$$

- $\sigma\{Y, W\} < 0 \iff$  les observations de  $Y$  au-dessus de  $\bar{Y}$  ont tendance à accompagner les observations de  $W$  **en dessous** de  $\bar{W}$ , et *vice-versa*
- $\sigma\{Y, W\} > 0 \iff$  les observations de  $Y$  au-dessus de  $\bar{Y}$  ont tendance à accompagner les observations de  $W$  **au-dessus** de  $\bar{W}$ , et *vice-versa*

- $\sigma\{Y, W\} = 0 \implies Y$  et  $W$  sont **sans corrélation**
- $Y, W$  **indépendantes**  $\implies \rho\{Y, W\} = 0$  (sans corrélation)
- $\rho\{Y, W\} = 0 \not\Rightarrow Y, W$  **indépendantes**, cependant
- $|\rho\{Y, W\}| \leq 1$  (conséquence de l'inégalité de Cauchy-Schwartz)
- $|\rho\{Y, W\}| = 1 \iff Y = aW + b$  pour une paire  $(a, b) \in \mathbb{R}^2$ ,

## Vecteurs aléatoires

Si  $Y_1, \dots, Y_n$  sont des variables aléatoires, alors

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}$$

est un **vecteur aléatoire**. L'**espérance** de  $\mathbf{Y}$  est

$$E\{\mathbf{Y}\} = \begin{pmatrix} E\{Y_1\} \\ \vdots \\ E\{Y_n\} \end{pmatrix}.$$

Les composantes de  $\mathbf{Y}$  n'ont pas nécessairement tous des distributions **identiques**.

La **matrice de variance-covariance** de  $\mathbf{Y}$  est la matrice symétrique

$$\sigma^2 \{\mathbf{Y}\} = (g_{i,j}), \quad \text{où } g_{i,j} = \begin{cases} \sigma^2 \{Y_i\} & i = j \\ \sigma \{Y_i, Y_j\} & i \neq j \end{cases}$$

ou encore

$$\sigma^2 \{\mathbf{Y}\} = \begin{pmatrix} \sigma^2 \{Y_1\} & \cdots & \sigma \{Y_1, Y_n\} \\ \vdots & \ddots & \vdots \\ \sigma \{Y_1, Y_n\} & \cdots & \sigma^2 \{Y_n\} \end{pmatrix}$$

Si les composantes de  $\mathbf{Y}$  sont **indépendantes** et ont toutes la **même variance**  $\sigma^2$ , alors

$$\sigma^2 \{\mathbf{Y}\} = \sigma^2 \mathbf{I}_n.$$

En pratique, nous travaillons généralement avec des **échantillons** de v.a. Si l'on observe  $\{(X_i, Y_i)\}_{i=1}^n$  à partir de la distribution conjointe de  $(X, Y)$  :

- $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  et  $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$ , les **moyennes d'échantillon**, sont des estimateurs sans biais de  $E\{X\}$  et  $E\{Y\}$ , respectivement ;
- $s_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  et  $s_Y^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$ , les **variances d'échantillon**, sont des estimateurs sans biais de  $\sigma^2\{X\}$  et  $\sigma^2\{Y\}$  ;
- $s_{XY} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$ , la **covariance d'échantillon**, est un estimateur sans biais de  $\sigma\{X, Y\}$ .

## 1.1.2 – Distributions importantes

La **fonction de répartition (cumulative)** (f.r.c.) de toute variable aléatoire continue  $Y$  est définie par

$$F_Y(y) = P(Y \leq y) = \int_{-\infty}^y f_Y(t) dt$$

que l'on considère comme fonction d'une variable réelle  $y$ . Alternativement, nous pouvons décrire la **loi** (distribution) de  $Y$  *via* la relation suivante entre  $f_Y(y)$  et  $F_Y(y)$  :

$$f_Y(y) = \frac{d}{dy} F_Y(y).$$

## Fonction de probabilité

La **fonction de densité de probabilité** (f.d.p.) d'une variable aléatoire continue  $Y$  est une fonction **intégrable**  $f_Y : Y(\mathcal{S}) \rightarrow \mathbb{R}$  telle que :

- $f_Y(y) > 0$  pour tout  $y \in Y(\mathcal{S})$  et  $\lim_{y \rightarrow \pm\infty} f_Y(y) = 0$ ;
- $\int_{\mathcal{S}} f_Y(y) dy = 1$ ;
- pour toute paire  $(a, b) \in \mathbb{R}^2$ ,

$$\begin{aligned} P(a < Y < b) &= P(a \leq Y < b) = P(a < Y \leq b) = P(a \leq Y \leq b) \\ &= F_Y(b) - F_Y(a) = \int_a^b f(y) dy. \end{aligned}$$

**Loi normale** : la f.r.c. de la v.a.  $Y \sim \mathcal{N}(\mu, \sigma^2)$  est

$$F_Y(y) = P(Y \leq y) = \Phi(y),$$

avec

$$f_Y(y) = \Phi'(y) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left( -\frac{1}{2} \left( \frac{y - \mu}{\sigma} \right)^2 \right).$$

**Loi  $\chi^2$**  : la f.d.p. de la v.a.  $Y \sim \chi^2(\nu)$  est

$$f_Y(y; \nu) = \begin{cases} \frac{y^{\frac{\nu}{2}-1} e^{-\frac{y}{2}}}{2^{\frac{\nu}{2}} \Gamma\left(\frac{\nu}{2}\right)}, & y > 0; \\ 0, & \text{autrement} \end{cases}$$

où  $\Gamma(\cdot)$  représente la **fonction Gamma**.



Si  $U_i \sim \chi^2(\nu_i)$ ,  $i = 1, 2$ , et  $U_1, U_2$  sont indépendantes, alors

$$U = U_1 + U_2 \sim \chi^2(\nu_1) + \chi^2(\nu_2) = \chi^2(\nu_1 + \nu_2).$$

Il existe un lien important entre la loi normale centrée réduite  $\mathcal{N}(0, 1)$  et la loi  $\chi^2(1)$  : si  $Z \sim \mathcal{N}(0, 1)$ , alors  $Z^2 \sim \chi^2(1)$ .

**Loi de Student** : si  $Z \sim \mathcal{N}(0, 1)$  et  $U \sim \chi^2(\nu)$ ,  $Z, U$  indépendantes :

$$t = \frac{Z}{\sqrt{U/\nu}} \sim t(\nu),$$

suit une **loi  $T$  de Student avec  $\nu$  degrés de liberté**.


**Loi de Fisher** : si  $U_i \sim \chi^2(\nu_i)$ ,  $i = 1, 2$  et  $U_1, U_2$  indépendantes :

$$F = \frac{U_1/\nu_1}{U_2/\nu_2} \sim F(\nu_1, \nu_2),$$

suit une loi de **Fisher avec  $\nu_1$  et  $\nu_2$  degrés de liberté**.

Je vous encourage à savoir lire les tableaux de f.r.c. et les fonctions R correspondantes :

- `qt()`, `dt()`, `pt()`, `rt()`, et
- `qf()`, `df()`, `pf()`, `rf()`.

**Table VI** The  $t$  Distribution

$$P(T \leq t) = \int_{-\infty}^t \frac{\Gamma[(r+1)/2]}{\sqrt{\pi r} \Gamma(r/2) (1 + w^2/r)^{(r+1)/2}} dw$$

$$P(T \leq -t) = 1 - P(T \leq t)$$

	$P(T \leq t)$						
	0.60	0.75	0.90	0.95	0.975	0.99	0.995
$r$	$t_{0.40}(r)$	$t_{0.25}(r)$	$t_{0.10}(r)$	$t_{0.05}(r)$	$t_{0.025}(r)$	$t_{0.01}(r)$	$t_{0.005}(r)$
1	0.325	1.000	3.078	6.314	12.706	31.821	63.657
2	0.289	0.816	1.886	2.920	4.303	6.965	9.925
3	0.277	0.765	1.638	2.353	3.182	4.541	5.841

Table VII The  $F$  Distribution

$$P(F \leq f) = \int_0^f \frac{\Gamma[(r_1 + r_2)/2](r_1/r_2)^{r_1/2} w^{r_1/2-1}}{\Gamma(r_1/2)\Gamma(r_2/2)(1 + r_1 w/r_2)^{(r_1+r_2)/2}} dw$$





Table VII continued

$$P(F \leq f) = \int_0^f \frac{\Gamma[(r_1 + r_2)/2](r_1/r_2)^{r_1/2} w^{r_1/2-1}}{\Gamma(r_1/2)\Gamma(r_2/2)(1 + r_1 w/r_2)^{(r_1+r_2)/2}} dw$$

$\alpha$	$P(F \leq f)$	Den. d.f. $r_2$	Numerator Degrees of Freedom, $r_1$									
			1	2	3	4	5	6	7	8	9	10
0.05	0.95	1	161.4	199.5	215.7	224.6	230.2	234.0	236.8	238.9	240.5	241.9
0.025	0.975		647.79	799.50	864.16	899.58	921.85	937.11	948.22	956.66	963.28	968.63
0.01	0.99		4052	4999.5	5403	5625	5764	5859	5928	5981	6022	6056
0.05	0.95	2	18.51	19.00	19.16	19.25	19.30	19.33	19.35	19.37	19.38	19.40
0.025	0.975		38.51	39.00	39.17	39.25	39.30	39.33	39.36	39.37	39.39	39.40
0.01	0.99		98.50	99.00	99.17	99.25	99.30	99.33	99.36	99.37	99.39	99.40
0.05	0.95	3	10.13	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79
0.025	0.975		17.44	16.04	15.44	15.10	14.88	14.73	14.62	14.54	14.47	14.42
0.01	0.99		34.12	30.82	29.46	28.71	28.24	27.91	27.67	27.49	27.35	27.23
0.05	0.95	4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96
0.025	0.975		12.22	10.65	9.98	9.60	9.36	9.20	9.07	8.98	8.90	8.84
0.01	0.99		21.20	18.00	16.69	15.98	15.52	15.21	14.98	14.80	14.66	14.55
0.05	0.95	5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74
0.025	0.975		10.01	8.43	7.76	7.39	7.15	6.98	6.85	6.76	6.68	6.62
0.01	0.99		16.26	13.27	12.06	11.39	10.97	10.67	10.46	10.29	10.16	10.05
0.05	0.95	6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06
0.025	0.975		8.81	7.26	6.60	6.23	5.99	5.82	5.70	5.60	5.52	5.46
0.01	0.99		13.75	10.92	9.78	9.15	8.75	8.47	8.26	8.10	7.98	7.87
0.05	0.95	7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64
0.025	0.975		8.07	6.54	5.89	5.52	5.29	5.12	4.99	4.90	4.82	4.76
0.01	0.99		12.25	9.55	8.45	7.85	7.46	7.19	6.99	6.84	6.72	6.62

## Théorème central limite

**Théorème :** soient  $X_1, \dots, X_n$  des v.a. normales indépendantes de moyennes  $\mu_1, \dots, \mu_n$  et d'écart-types  $\sigma_1, \dots, \sigma_n$ . Alors

$$X_1 + \dots + X_n \sim \mathcal{N}(\mu_1 + \dots + \mu_n, \sigma_1^2 + \dots + \sigma_n^2).$$

Si  $\mu_i \equiv \mu$  et  $\sigma_i^2 \equiv \sigma$  pour  $i = 1, \dots, n$ , alors  $X_1 + \dots + X_n \sim \mathcal{N}(n\mu, n\sigma^2)$ .

**Théorème :** soient  $X_1, \dots, X_n$  des v.a. normales indépendantes de moyenne  $\mu$  et d'écart-type  $\sigma$ . Soit  $\bar{X}$  la moyenne d'échantillon. Alors

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

**Théorème :** soient  $X_1, \dots, X_n$  des v.a. indépendantes de moyenne  $\mu$  et d'écart-type  $\sigma$ . Soit  $\bar{X}$  la moyenne d'échantillon. Alors

$$Z_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \rightarrow Z \sim \mathcal{N}(0, 1), \quad \text{lorsque } n \rightarrow \infty.$$

soient  $X_1, \dots, X_n$  des v.a. normales indépendantes de moyenne  $\mu$  et d'écart-type  $\sigma$  **inconnu**. Soit  $\bar{X}$  et  $S^2$  la moyenne et la variance d'échantillon, respectivement. Alors

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n - 1),$$

suit une **loi  $T$  de Student avec  $\nu = n - 1$  degrés de liberté**.

## 1.2 – Calcul multivarié

Soit  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  une fonction **différentiable**. Si  $\mathbf{Y} = (Y_1, \dots, Y_n)$ , la **dérivée** de  $f$  par rapport à  $\mathbf{Y}$  est

$$\nabla_{\mathbf{Y}} f(\mathbf{Y}) = \begin{pmatrix} \frac{\partial f(\mathbf{Y})}{\partial Y_1} \\ \vdots \\ \frac{\partial f(\mathbf{Y})}{\partial Y_n} \end{pmatrix}.$$

Le **gradient**  $\nabla$  est un **opérateur linéaire** :

$$\nabla_{\mathbf{Y}}(af + bg)(\mathbf{Y}) = a\nabla_{\mathbf{Y}}f(\mathbf{Y}) + b\nabla_{\mathbf{Y}}g(\mathbf{Y}).$$

If  $f(\mathbf{Y}) \equiv a$ , alors  $\nabla_{\mathbf{Y}}f(\mathbf{Y}) = \mathbf{0}$ . Si  $f(\mathbf{Y}) = \mathbf{Y}^\top \mathbf{v}$ , alors  $\nabla_{\mathbf{Y}}f(\mathbf{Y}) = \mathbf{v}$ .

## 1.3 – Algèbre matricielle

Soient  $A \in M_{m,n}(\mathbb{R})$  et  $\mathbf{Y}$  un vecteur aléatoire. Si  $\mathbf{W} = A\mathbf{Y}$ , alors

$$E\{\mathbf{W}\} = AE\{\mathbf{Y}\} \quad \text{et} \quad \sigma^2\{\mathbf{W}\} = A\sigma^2\{\mathbf{Y}\}A^\top.$$

De plus, si  $\mathbf{Y} \sim \mathcal{N}(E\{\mathbf{Y}\}, \sigma^2\{\mathbf{Y}\})$ , alors

$$\mathbf{W} \sim N(E\{\mathbf{W}\}, \sigma^2\{\mathbf{W}\}) = \mathcal{N}(AE\{\mathbf{Y}\}, A\sigma^2\{\mathbf{Y}\}A^\top).$$

Si  $A \in M_{n,n}(\mathbb{R})$ , la **trace** de  $A$  est  $\text{tr}(A) = \sum_{i=1}^n a_{ii} = a_{11} + a_{22} + \cdots + a_{nn}$ .

La trace est un **opérateur linéaire** :  $\text{tr}(kA + B) = k \text{tr} A + \text{tr} B$ ; on a aussi  $\text{tr}(AB) = \text{tr}(BA)$  (lorsque les matrices sont **compatibles**).



La **transposition** d'une matrice  $A$ , notée  $A^\top$ , est obtenue en interchangeant ses **lignes** et ses **colonnes**, ou simplement en **réfléchissant** la matrice le long de sa **diagonale principale**.

**Propriétés:** si  $A \in M_{m,n}(\mathbb{R})$  et  $k \in \mathbb{R}$ , alors

- $(A^\top)^\top = A$
- $k^\top = k$
- $(kA + B)^\top = kA^\top + B^\top$
- $(AB)^\top = B^\top A^\top$

## 1.4 – Formes quadratiques

Une **forme quadratique symétrique** en  $Y_1, \dots, Y_n$  est une expression de la forme

$$Q_A(\mathbf{Y}) = \mathbf{Y}^\top A \mathbf{Y} = \sum_{i,j=1}^n a_{i,j} Y_i Y_j,$$

où  $A$  est une **matrice symétrique**  $n \times n$  ( $A^\top = A$ ).

Un certain nombre de quantités importantes apparaissant en analyse de régression peuvent être exprimées sous de telles formes.

Les **degrés de liberté** d'une forme quadratique symétrique  $Q_A(\mathbf{Y})$  peuvent être obtenus en calculant le **rang** de la matrice associée  $A$ .

Par exemple, la matrice symétrique associée à la forme quadratique symétrique  $Q_A(\mathbf{Y}) = 4Y_1^2 + 7Y_1Y_2 + 2Y_2^2$  est

$$A = \begin{pmatrix} 4 & 7/2 \\ 7/2 & 2 \end{pmatrix}; \quad Q_A \text{ a } 2 \text{ degrés de liberté.}$$

**Théorème:** soient  $Q_1, \dots, Q_K$  des formes quadratiques symétriques en  $\mathbf{Y}$  avec matrices symétriques associées  $A_1, \dots, A_K$ , respectivement. Si  $a_i \in \mathbb{R}$  pour tout  $i = 1, \dots, K$ , alors

$$Q = a_1Q_1 + \dots + a_KQ_K$$

est une forme quadratique symétrique en  $\mathbf{Y}$  avec matrice symétrique associée

$$A = a_1A_1 + \dots + a_KA_K.$$

Pour une matrice  $B$  générale de dimension  $n \times n$ , nous avons

$$\nabla_{\mathbf{Y}} (\mathbf{Y}^\top B \mathbf{Y}) = (B^\top + B) \mathbf{Y}.$$

Ainsi le gradient d'une forme quadratique symétrique  $Q_A(\mathbf{Y})$  est

$$\nabla_{\mathbf{Y}} Q_A(\mathbf{Y}) = 2A\mathbf{Y}.$$

On peut montrer que **chaque** expression de la forme  $\mathbf{Y}^\top B \mathbf{Y}$  peut être associée à une matrice symétrique  $A$ . Nous supposons donc que chaque forme de ce type est symétrique.

Le rôle joué par les formes quadratiques dans le calcul multi-variable est analogue au rôle joué par  $f(x) = ax^2$  dans le calcul différentiel ordinaire.

Les **valeurs propres** d'une matrice  $A$  de taille  $n \times n$  sont les racines du **polynôme caractéristique**  $p_A(\lambda)$  de  $A$  :  $p_A(\lambda) = \det(A - \lambda \mathbf{I}_n) = 0$ .

Il existe  $n$  telles racines (complexes), pas nécessairement distinctes.

Si  $\lambda$  est une valeur propre de  $A$ , alors  $\exists \mathbf{v} \neq \mathbf{0}$  tel que  $A\mathbf{v} = \lambda\mathbf{v}$ . Si de plus  $A$  est réelle et symétrique, toutes ses valeurs propres sont **réelles**.

Soit  $Q_A(\mathbf{Y})$  une forme quadratique avec  $\text{eig}(A) = \{\lambda_1, \dots, \lambda_n\} \subseteq \mathbb{R}$  :

- si  $\lambda_i > 0$  pour tout  $i$ ,  $Q_A(\mathbf{Y})$  et  $A$  sont dites **définies positives** ;
- si  $\lambda_i < 0$  pour tout  $i$ ,  $Q_A(\mathbf{Y})$  et  $A$  sont dites **définies négatives** ;
- si  $\lambda_i \lambda_j < 0$  pour une paire  $i, j$  quelconque,  $Q_A(\mathbf{Y})$  et  $A$  sont **indéfinies**.

## 1.4.1 – Théorème de Cochran

Soient  $\mathbf{Y} = (Y_1, \dots, Y_n) \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ .

Supposons que

$$\mathbf{Y}^\top \mathbf{Y} = Q_1(\mathbf{Y}) + \dots + Q_K(\mathbf{Y}),$$

où les  $Q_k$  sont des formes quadratiques (semi-)définies positives avec  $r_k (= \text{rang}(A_k))$  degrés de liberté, pour  $k = 1, \dots, K$ .

Si  $r_1 + \dots + r_K = n$ , alors  $Q_1(\mathbf{Y}), \dots, Q_K(\mathbf{Y})$  sont **indépendantes** et

$$\frac{Q_k(\mathbf{Y})}{\sigma^2} \sim \chi^2(r_k), \quad k = 1, \dots, K.$$

En particulier, si  $K = 2$  et  $r_1 = r$ , alors  $Q_2(\mathbf{Y})/\sigma^2 \sim \chi^2(n - r)$ .

## 1.4.2 – Formes quadratiques importantes

Pour tout entier positif  $n$ , nous définissons deux **matrices spéciales** :

$$\mathbf{J}_n = \mathbf{J} = \begin{pmatrix} 1 & \cdots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 1 \end{pmatrix} \quad \text{et} \quad \mathbf{1}_{n \times 1} = \mathbf{1}_n = \mathbf{1} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}.$$

On note que  $\mathbf{1}_n^\top \mathbf{1}_n = n$  et  $\mathbf{1}_n \mathbf{1}_n^\top = \mathbf{J}_n$ . Soit  $\mathbf{Y} = (Y_1, \dots, Y_n) \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$  un vecteur aléatoire. Quelles sont les matrices symétriques associées à

$$Q_A(\mathbf{Y}) = \sum_{i=1}^n Y_i^2, \quad Q_B(\mathbf{Y}) = n\bar{Y}^2, \quad \text{et} \quad Q_C(\mathbf{Y}) = \sum_{i=1}^n (Y_i - \bar{Y})^2?$$

Ré-écrivons les formes quadratiques en  $\mathbf{Y}$  pour obtenir (page suivante) :

$$Q_A(\mathbf{Y}) = \mathbf{Y}^\top \mathbf{Y} = \mathbf{Y}^\top \mathbf{I}_n \mathbf{Y} \implies A = \mathbf{I}_n;$$

$$Q_B(\mathbf{Y}) = n \left( \frac{1}{n} \sum_{i=1}^n Y_i \right)^2 = \frac{1}{n} \sum_{i,j=1}^n Y_i Y_j = \frac{1}{n} \mathbf{Y}^\top \mathbf{1}_n \mathbf{1}_n^\top \mathbf{Y} \implies B = \frac{1}{n} \mathbf{J}_n;$$

$$Q_C(\mathbf{Y}) = \sum_{i=1}^n Y_i^2 - n\bar{Y}^2 = \mathbf{Y}^\top \mathbf{I}_n \mathbf{Y} - \frac{1}{n} \mathbf{Y}^\top \mathbf{J}_n \mathbf{Y} \implies C = \mathbf{I}_n - \frac{1}{n} \mathbf{J}_n.$$

Puisque  $\text{rang}(A) = n$ ,  $\text{rang}(B) = 1$ , et  $\text{rang}(C) = n - 1$ , le théorème de Cochran implique que  $Q_A(\mathbf{Y})$ ,  $Q_B(\mathbf{Y})$ , et  $Q_C(\mathbf{Y})$  sont des v.a. **indépendantes**, et que

$$\frac{Q_A(\mathbf{Y})}{\sigma^2} = \frac{\mathbf{Y}^\top \mathbf{Y}}{\sigma^2} \sim \chi^2(n), \quad \frac{Q_B(\mathbf{Y})}{\sigma^2} = \frac{n\bar{Y}^2}{\sigma^2} \sim \chi^2(1), \quad \frac{Q_C(\mathbf{Y})}{\sigma^2} = \frac{\text{SST}}{\sigma^2} \sim \chi^2(n-1).$$



## 1.5 – Optimisation

Soient  $A$  une matrice symétrique  $n \times n$ ,  $\mathbf{v} \in \mathbb{R}^n$ ,  $c \in \mathbb{R}$ , et

$$f(\mathbf{Y}) = \frac{1}{2} \mathbf{Y}^\top A \mathbf{Y} - \mathbf{Y}^\top \mathbf{v} + c.$$

Notons que  $f$  est **dérivable**. Les **points critiques** de  $f$  satisfont à

$$\nabla_{\mathbf{Y}} f(\mathbf{Y}) = A\mathbf{Y} - \mathbf{v} = \mathbf{0} \implies A\mathbf{Y} = \mathbf{v}.$$

Si  $A$  est **inversible** ( $\det(A) \neq 0$ ), le point critique  $\mathbf{Y}^* = A^{-1}\mathbf{v}$  est **unique**.

Si  $A$  est **singulière** ( $\det(A) = 0$ ), il y a soit **pas** de point critique (si  $\mathbf{v} \notin \text{image}(A)$ ) ou une **infinité** de points critiques (si  $\mathbf{v} \in \text{image}(A)$ ).

Lorsque  $A$  est **inversible**:

- si  $A$  est **définie positive**, alors  $f$  atteint son **minimum global** en  $\mathbf{Y}^* = A^{-1}\mathbf{v}$ ;
- si  $A$  est **définie négative**, alors  $f$  atteint son **maximum global** en  $\mathbf{Y}^* = A^{-1}\mathbf{v}$ ;
- si  $A$  est **indéfinie** (c'est-à-dire que  $A$  possède des valeurs propres positives **et** des valeurs propres négatives), alors  $\mathbf{Y}^* = A^{-1}\mathbf{v}$  est un **col** de  $f$ .

Si les valeurs propres peuvent être **nulle**, nous remplaçons “défini” par “semi-défini”.